



# 基于深度学习的岩石薄片显微图像分类

**摘要:** 利用显微镜对岩石薄片进行岩矿鉴定,是地质研究中一项基本工作。本文提出了一种基于深度学习方法对岩石薄片显微图像进行分类。采用了深度学习中的 Inception-V3 卷积神经网络模型,运用迁移学习的方法实现对不同种类的岩石薄片显微图像进行识别。建立了一个 10 种常见岩石图像的数据库,实验结果表明经过训练和测试达到 98% 以上的识别概率。研究表明深度学习方法能够提取岩石中的有效特征,对识别岩石薄片显微图像有很大的帮助,可以有效地提高地质工作者的工作效率,尝试把长期依赖经验的岩矿鉴定工作向智能化方向推进。

**关键词:** 深度学习; 岩石薄片显微图像; 卷积神经网络; 图像分类

**Abstract:** It is a basic work in geological research to identify rock and mineral deposits by means of microscopy. In this paper, a deep learning method is proposed to classify the microscopic images of rock slices. Inception-V3 convolution neural network model in deep learning is adopted, and different kinds of rock slice micro-images are recognized by migration learning method. A database of 10 kinds of common rock images is established. The experimental results show that the recognition probability is over 98% after training and testing. The research shows that the deep learning method can extract the effective features of rock, which is very helpful to identify the microscopic image of rock slices, and can effectively improve the work efficiency of geologists, trying to promote the long-term experience-dependent rock and mineral identification work to the direction of intelligence.

**Key words:** Deep learning; Rock slice microscopic image; Convolution neural network; Image classification

## 引言

岩石是地质工作者最基本的研究对象,利用岩石薄片对岩石结构和矿物成分进行鉴定,是地质工作者研究岩石成因最常规的方法之一。

岩石薄片提供的微观数据可以帮助研究人员准确地确定岩石的结构、类型、空隙演化规律、裂隙发育与控制等情况。付晶<sup>[1]</sup>通过计算岩石薄片的胶结率和溶解率,对储层定量成岩相研究。冉新权<sup>[2]</sup>利用微观孔隙结构特征参数和宏观物性参数的相关性,计算孔隙结构的分级参数。周翔<sup>[3]</sup>通过推断储层微观孔隙的结构成因,对鄂尔多斯盆地致密油储层进行分类。钟大康<sup>[4]</sup>利用薄片的孔隙分析,研究陇东地区颗粒砂岩的成岩作用和孔隙演化规律。张少敏<sup>[5]</sup>通过对块状泥晶云岩相储层孔隙度、孔喉半径、渗透率等数据进行分析,研究了准噶尔盆地吉木萨尔凹陷二叠系芦草沟组沉积岩的岩相类型;潘荣<sup>[6]</sup>通过定量计算沉积物固结成岩后的初始孔隙度、压实损孔孔隙度、胶结损孔孔隙度、溶蚀损孔孔隙度和裂缝增孔孔隙度,对库车坳陷克拉苏冲断带克深区块深部巴什基奇克组致密储层进行了孔隙演化定量研究;张立强<sup>[7]</sup>依据钙质胶结物、塑性,利用视溶蚀率、视钙质胶结率、裂缝率、视压实率成岩参数计算刚性岩屑的含量,将阿合组致密砂岩分为 4 类;久凯<sup>[8]</sup>通过分析页岩储集空间的成因和孔隙发育的位置,将龙马溪组页岩储层储集空间划分为 3 个类别;张震<sup>[9]</sup>通过分析裂缝的发育特征、成因机制以及控制因素,得出松辽盆地朝阳沟油田储层主要发育的 4 组构造裂缝;李海燕<sup>[10]</sup>利用建立判别函数的方法,通过计算渗透率来求取各类微观参数,对微观孔隙结构进行分类;王洛<sup>[11]</sup>通过对准噶尔盆地滴西地区石炭系火山岩储集空间的分析,得出孔隙类型是以溶孔为主导、裂缝类型以构造峰为绝对主导的结论。

使用数字图像处理技术分析岩石薄片图像可以有效的提高处理速度、减少系统误差。Feng Jiang<sup>[12]</sup>结合线性迭代聚类算法和区域融合技术对 3 种多角度正交偏振砂岩薄片图像进

行了分割；Hossein Izadi<sup>[13]</sup>使用增量颜色聚类策略，从火成岩的样本薄片提取了 12 种颜色特征，提取薄片图像中的矿物，准确率可以达到 92.15%；Bibo Lu<sup>[14]</sup>利用水平集曲线演化方法，自动提取岩石薄片图像中的颗粒边缘；Boguslaw Obara<sup>[15]</sup>利用微裂隙分割算法对粗粒砂岩薄片图像进行分割；Pece V. Gorsevski<sup>[16]</sup>利用细胞自动机的方法提取变质岩的特征，并将其用于检测变质岩颗粒的边界；Boyuan Ma<sup>[17]</sup>提出一种基于图割的方法，利用 3 维信息以更精确地提取颗粒的边缘特征；Ivan Mingireanov Filho<sup>[18]</sup>利用最佳路径森林算法，分割砂岩薄片图像中的粘连颗粒。对两种砂岩样本进行测试并达到 94.8% 的平均准确率；Matthias Jungmann<sup>[19]</sup>利用区域竞争和边界加权融合的方法对岩石薄片图像进行自动分割。

目前深度学习技术在多个领域得到广泛应用。在 ImageNet 数据集的基础上，有许多不同场景的比赛。例如：图像分类、目标定位、目标检测、视频目标检测、场景分类。在 2012 年的 ISLVR 比赛，Alex Krizhevsky<sup>[20]</sup>提出了 AlexNet 网络，对 ImageNet 数据中的一百多万张图片中的 1000 个类别进行识别将错误率从 25% 降到 16%；Christian Szegedy<sup>[21]</sup>在 2014 年提出了 GoogleNet 网络，在 2014 年的 ImageNet 分类和检测，获得冠军；周爱明<sup>[22]</sup>利用深度学习的 Caffe 框架，使用迁移学习的方法，在 ImageNet 数据集的基础上进行模型的训练，对 6 个科 1174 种蝴蝶共 4464 张图片进行训练和测试，6 个科的蝴蝶平均识别准确率为 95.8%。

利用神经网络开展地质方面的研究可以追溯到上个世纪九十年代。蔡煌东<sup>[23]</sup>使用 BP 神经网络对我国沉积碳酸盐中的菱锰矿进行研究，选取了 96 个具有代表性的样品分成四类进行识别，识别率为 100%；席道瑛<sup>[24]</sup>利用 BP 网络对 34 个石榴子石样本中的 5 种主要化学成分分成四类进行识别，将判断的结果和实际值相比较，正确率可达 94%，并且对 25 个蓝宝石样本中的 7 种主要化学成分分成三类进行识别，将判断的结果和实际值相比较，正确率可达 88%。近年来，地质研究人员也开始逐渐使用深度学习技术开展研究。李苍柏<sup>[25]</sup>对如何使用深度学习在地质学科不同领域的应用进行了规划和设想。程国建<sup>[26]</sup>利用卷积神经网络实现了对长石砂岩薄片图像进行粒度识别，可以较好的将其分为粗粒度、中粒度和细粒度，测试集准确度达到 98.5%；陈晓君<sup>[27]</sup>基于人工神经网络模型，运用 4 种不同的 BP 训练算法，实现了对 10 种不同岩石岩性的预测；白林<sup>[28]</sup>采用深度学习的方法，对野外采集的岩石进行数据采集，收集了 15 种岩石的图像数据进行分类识别，达到 63% 识别准确率；张野<sup>[29]</sup>使用 Inception-V3 深度学习卷积神经网络模型，对 571 张三种岩石进行训练和测试，三种岩石分类结果正确，分类概率值达到 90% 以上。此模型可以适用于多尺度、多角度及部分岩石遮挡情况下的岩性识别。

本文基于卷积神经网络和深度学习中的迁移学习方法。在规格为 DM2700P LeiCa 电子显微镜下，采集了 10 中不同种类的岩石。每种岩石薄片显微图像分为单偏光和正交偏光，并且从网上找了部分种类的岩石薄片显微图像，建立了总共 1298 张不同种类的岩石薄片显微图像数据集。分别对这些岩石薄片显微图像进行训练、验证和测试。证明了在有足够多的数据下，该模型不仅可以提高识别岩石薄片显微矿物图像的概率，也可以准确的把岩石薄片显微矿物图像进行分类，同时验证了该模型具有良好的泛化能力。

## 1 图像数据和方法

### 1.1 岩石薄片显微图像数据

岩石薄片显微图像一部分是在规格为 DM2007P，放大倍数为 50 的 LeiCa 电子显微镜下观察岩石薄片，并对其进行数据采集。考虑到岩石具有在单一光源下不易识别的性质，在采集过程中部分岩石使用了正交偏光。本实验选取了比较常见的鲕粒、堇青石、石榴子石、红柱石、电气石、十字石、阳起石、长石、角闪石、辉石 10 种岩石<sup>[30-39]</sup>薄片显微图像。表 1 是采集的岩石薄片显微图像的种类与数量。在岩石薄片显微图像中每一种各随机选取 3 张作为测试集，然后再从岩石薄片显微图像中随机挑选 30 张作为验证集，将剩余的图片作为训练集。另一部分岩石薄片显微图像来自网络，总共是 90 张，均是在显微镜下拍摄的。这些

来源不同的岩石薄片显微图像，将其作为测试集，主要是为了检测基于深度学习的岩石薄片显微图像训练获得的模型是否具有好的泛化能力。

表 1 岩石薄片显微图像种类与数量

岩石薄片显微图像 种类	岩石薄片显微图像 数量	单偏光岩石薄片显微 图像	正交偏光岩石薄片显 微图像
鲕粒	155	107	48
堇青石	115	64	51
石榴子石	126	75	51
红柱石	146	78	68
电气石	110	58	52
十字石	131	70	61
阳起石	141	102	39
长石	124	124	0
角闪石	129	129	0
辉石	124	124	0

1.2 基于迁移学习的岩石薄片分类方法

1.2.1 迁移学习的算法流程

深度学习需要利用大量样本数据提取特征以进行后续的认识和分类。但是由于训练过程需要花费很长的时间，所以需要利用迁移学习技术。迁移学习是使用预训练模型应用在其他领域。基于迁移学习的岩石薄片识别流程图，如图 1 所示。


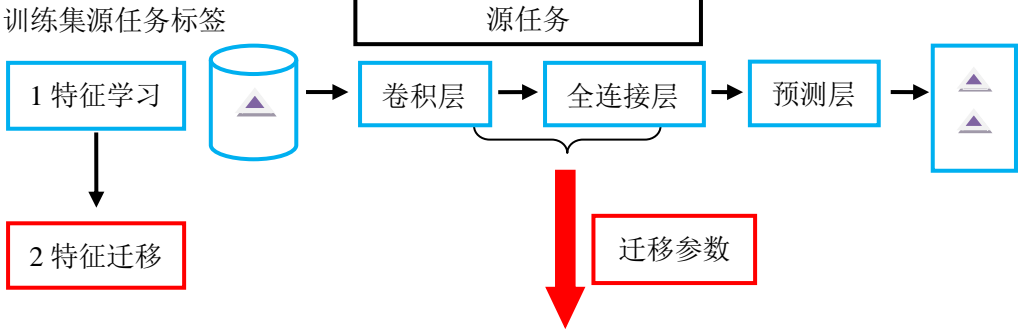


图 1 基于迁移学习的岩石薄片识别流程

1.2.2 预训练模型与神经网络

传统的机器学习要重新构建一个模型，这就需要浪费大量的人力与物力。而迁移学习适合于有一定的相关性的领域。从源任务到目标任务只需要微调或者是无需改动就可以运用到新的领域。迁移学习可以减少大量的重复劳动，提高生产中的效率。此外，迁移学习适用于训练样本数据较少，而且训练时间远少于深度学习模型训练时间。迁移学习模型构建，如图 2 所示。






图 2 迁移学习模型构建

Inception-V3 模型的卷积层、池化层以及混合层结构，如图 3 所示，整个模型前 3 个是卷积层，紧接着是一个池化层；接下来有 2 个卷积层，连接 1 个池化层；最后是 11 个混合层。Inception-V3 模型中的卷积层用来提取岩石薄片显微图像的特征；池化层主要是改变卷积之后特征图的大小，降低维度，减少冗余特征；混合层是包括卷积层、池化层、softmax 层，主要使用小的卷积核，降低网络参数，减少计算量，并且使用卷积核的分解，用不同的卷积核，感受野不一样，从不同的方向提取不同的特征，最后使用深度连接，将不同的卷积核提取的特征图拼接在一起。




图 3 Inception-V3 模型的卷积层、池化层以及混合层结构

### 1.2.3 激活函数 ReLU

使用神经网络进行建模时，反复使用线性关系无法很好的模拟人类识别与分类的过程，为了模拟人类认知中出现的复杂的非线性关系，需要设计并使用非线性激活函数。随着网络层数的加深，网络参数的增加会出现梯度消失、计算速度缓慢、收敛速度比较慢等问题。本文采用线性修正单元 ReLU (Rectified linear units) 作为激活函数： $f(x) = \max(0, x)$ ，

$x < 0, f(x) = 0; x \geq 0, f(x) = x$ 。ReLU 函数，如图 4 所示。将卷积层的输出结果做一次非线性的映射，它忽略了输入为负值对下一层网络的影。因此可以显著提高计算速度，同时加快了网络的收敛速度，有效地避免梯度消失问题。




图 4 ReLU 函数

### 1.2.4 Softmax 回归

训练集  $x = \{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$  包含  $m$  个标签的岩石薄片样本的数据， $x^{(i)}$  是第  $i$  个输入的岩石薄片显微图像， $y^{(i)} \in \{1, 2, 3, \dots, k\}$  是第  $i$  个岩石薄片对应的类别标签， $k$  是岩石薄片的类别总数。对于给定的测试输入  $z$ ， $z$  是某一个岩石薄片显微图像。利用假设函数对每一类别  $j$  估算出概率值  $p(y = j | z)$ ，即估计  $z$  的每一种分类结果出现的概率。因此，利用假设函数，将要输出一个  $k$  维的向量来表示  $k$  个估计的概率值，假设函数  $h_\theta(x)$  的形式如下：

$$h_\theta(z^{(i)}) = \begin{bmatrix} p(y^{(i)} = 1 | z^{(i)}; \theta) \\ p(y^{(i)} = 2 | z^{(i)}; \theta) \\ \vdots \\ p(y^{(i)} = k | z^{(i)}; \theta) \end{bmatrix} = \frac{1}{\sum_{i=1}^k e^{\theta_j^{T z^{(i)}}}} \begin{bmatrix} e^{\theta_1^{T z^{(i)}}} \\ e^{\theta_2^{T z^{(i)}}} \\ \vdots \\ e^{\theta_k^{T z^{(i)}}} \end{bmatrix} \quad (1)$$

其中  $\frac{1}{\sum_{i=1}^k e^{\theta_j^{T z^{(i)}}}}$  项对概率分布进行归一化，使得所有概率之和为 1， $z$  是  $d \times 1$  维的输入

变量， $d$  是输入变量的特征数，Softmax 的模型参数  $\theta$  是一个  $d \times k$  阶矩阵。模型训练的目标就是要找到最优参数  $\theta$ 。在训练过程中，通过不但改变参数  $\theta$  的取值，使某个代价函数  $J(\theta)$  取得极小值。本文选用了如下的代价函数  $J(\theta)$ ：

$$J(\theta) = -\frac{1}{d} \left[ \sum_{i=1}^d \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^{T z^{(i)}}}}{\sum_{l=1}^k e^{\theta_l^{T z^{(i)}}}} \right] \quad (2)$$

上式中  $1\{.\}$  是示性函数，其取值为： $1\{\text{值为真的表达式}\} = 1, 1\{\text{值为假的表达式}\} = 0$ 。

为了求解  $J(\theta)$  的最小值点，可以使用迭代优化算法中的梯度下降法求解方程(2)的极小值。根据偏导数和梯度的定义，可得到对应的梯度：

$$\nabla_{\theta} J(\theta) = -\frac{1}{d} [x^{(i)} (1\{y^{(i)} = j\} - p(y^{(i)} = j | x^{(i)}; \theta))] \quad (3)$$

$\nabla_{\theta} J(\theta)$  向量的第  $e$  个元素  $\frac{\partial J(\theta)}{\partial \theta_{jn}}$  是  $J(\theta)$  对  $\theta_j$  的第  $e$  个分量的偏导数。通过添加权重衰减项  $\frac{\lambda}{2} \sum_{i=1}^k \sum_{j=0}^n \theta_{ij}^2$  来修改代价函数，增加这个权重衰减项 ( $\gamma > 0$ )，代价函数就变成了严格的

凸函数，这时就可以保证得到唯一的解了，并且因为  $J(\theta)$  是凸函数，梯度下降法可以保证收敛到全局最优解。其中  $n$  代表输出样本的个数，此时代价函数转化为下式：

$$J(\theta) = -\frac{1}{d} \left[ \sum_{i=1}^d \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^{Tz^{(i)}}}}{\sum_{l=1}^k e^{\theta_l^{Tz^{(i)}}}} \right] + \frac{\gamma}{2} \sum_{i=1}^k \sum_{j=0}^n \theta_{ij}^2 \quad (4)$$

本文将数据集分成 3 部分：训练集，验证集，测试集， $\gamma$  按照从小到大的顺序依次从数据集里面取图片，然后再训练集上学习模型参数，在交叉验证集上验证误差，选择错误率最小的模型，最后在测试集上进行评估，得到  $\gamma$  最优的值。

为了使用优化算法，需要求得这个新函数  $J(\theta)$  的导数：


$$\nabla_{\theta} J(\theta) = -\frac{1}{d} [x^{(i)} (1\{y^{(i)} = j\} - p(y^{(i)} = j | x^{(i)}; \theta))] + \gamma \theta \quad (5)$$

通过最小化  $J(\theta)$ ，可以实现不同类别的概率值，从而实现 Softmax 回归模型。

## 2 模型训练设计与分析

### 2.1 训练过程

在训练过程中，迭代次数设为 1000，学习率设为 0.01，训练过程中每次随机选取 10 张岩石薄片显微图像作为训练集进行一次训练，并且选择 10 张图片进行交叉验证，每训练 10 次后即可确定模型参数，实现预测、判断和保存。图 5 给出在训练过程中训练准确率(Train accuracy rate)、交叉熵损失(Cross-entropy loss)随迭代次数(Epochs)的变化情况，其中准确率表示当前正确分类样本数量占全体样本数量的比例，交叉熵损失函数计算了真实值与预测值之间的误差，差值越小，表明预测结果越好。



(a) 训练准确率随迭代次数的变化

(b) 交叉熵损失随迭代次数的变化

图 5 训练准确率和交叉熵随迭代次数的变化


从图 5(a)可以看出，训练经过 200 轮后，准确率逐渐达到稳定状态，在 98% 附近产生小扰动。从图 5(b)可以看出，经过 200 轮的训练后，交叉熵损失函数迅速衰减到 0 并在之后保持稳定的状态。准确率和交叉熵损失函数的结果从客观指标上表明，模型训练结果较为理想。

### 2.2 验证数据

验证集中包含 10 种岩石薄片图像，参与验证图像共 30 张。参与验证的图像如图 6 所示，十行三列，每行均为一类岩石薄片图像。与一般自然图像相比，岩石薄片图像不易识别的特殊性，除图 6(22-30)外，验证图像不仅包含单偏光的岩石薄片图像，还包含正交偏光的岩石



薄片图像。








图 6 30 张验证岩石薄片显微图像

(1-3)鲕粒;(4-6)堇青石;(7-9)石榴子石;(10-12)红柱石;(13-15)电气石;(16-18)十字石;(19-21)阳起石;(22-24)长石;(25-27)角闪石;(28-30)辉石

### 2.3 验证结果分析

验证集包含 30 张岩石薄片图像，每类 3 张。表 2 给出验证集图像的分类结果，其中每行的数据表示对应岩石薄片被识别成某类岩石薄片的概率。由于本文考虑对 10 种岩石薄片图像进行分，因此对每个输入岩石薄片显微图像进行识别都会得到 10 个概率值，最后将 10 个概率值中最大值对应的岩石种类认定其归属类别。为方便观察，表 2 中将对应的最大概率值加粗显示。结果显示，模型对验证集中岩石薄片显微图像分类识别率值为 98.1%，仅有图 5-4、图 5-16、图 5-26 识别率在 95%-96%之间，其余均在 98%以上。

表 2 验证集岩石薄片显微图像的分类结果


训练集 图像	分类识别概率									
	鲕粒	堇青 石	石榴 子石	红柱 石	电气 石	十字 石	阳起 石	长石	角闪 石	辉石
图 5-1	<b>0.991</b>	0.000	0.001	0.001	0.000	0.007	0.000	0.000	0.00	0.000
图 5-2	<b>0.997</b>	0.000	0.000	0.001	0.001	0.001	0.000	0.000	0.000	0.000
图 5-3	<b>0.995</b>	0.000	0.000	0.000	0.000	0.005	0.000	0.000	0.000	0.000
图 5-4	0.004	<b>0.959</b>	0.019	0.004	0.001	0.001	0.000	0.001	0.000	0.010
图 5-5	0.018	<b>0.981</b>	0.000	0.000	0.000	0.001	0.000	0.000	0.000	0.000
图 5-6	0.000	<b>0.997</b>	0.000	0.000	0.000	0.002	0.000	0.000	0.000	0.000
图 5-7	0.001	0.000	<b>0.999</b>	0.000	0.000	0.000	0.000	0.000	0.000	0.000
图 5-8	0.011	0.001	<b>0.986</b>	0.000	0.000	0.000	0.000	0.000	0.002	0.000
图 5-9	0.000	0.000	<b>1.000</b>	0.000	0.000	0.000	0.000	0.000	0.000	0.000
图 5-10	0.010	0.000	0.008	<b>0.982</b>	0.000	0.000	0.000	0.000	0.000	0.000
图 5-11	0.010	0.000	0.000	<b>0.986</b>	0.000	0.003	0.000	0.000	0.000	0.000

图 5-12	0.005	0.000	0.001	<b>0.991</b>	0.000	0.002	0.000	0.000	0.000	0.000
图 5-13	0.001	0.001	0.000	0.001	<b>0.995</b>	0.000	0.003	0.000	0.000	0.000
图 5-14	0.001	0.001	0.000	0.002	<b>0.994</b>	0.000	0.001	0.000	0.000	0.000
图 5-15	0.000	0.000	0.000	0.000	<b>0.993</b>	0.006	0.000	0.000	0.000	0.000
图 5-16	0.002	0.002	0.004	0.025	0.001	<b>0.954</b>	0.005	0.003	0.000	0.005
图 5-17	0.001	0.000	0.000	0.004	0.001	<b>0.993</b>	0.001	0.000	0.000	0.000
图 5-18	0.005	0.000	0.000	0.001	0.000	<b>0.992</b>	0.000	0.001	0.000	0.000
图 8-19	0.002	0.001	0.008	0.004	0.001	0.000	<b>0.982</b>	0.001	0.000	0.001
图 5-20	0.001	0.000	0.000	0.002	0.002	0.004	<b>0.991</b>	0.000	0.000	0.001
图 5-21	0.000	0.000	0.000	0.002	0.000	0.005	<b>0.988</b>	0.000	0.004	0.000
图 5-22	0.003	0.010	0.002	0.000	0.000	0.000	0.000	<b>0.981</b>	0.003	0.000
图 5-23	0.000	0.000	0.000	0.000	0.000	0.000	0.000	<b>1.000</b>	0.000	0.000
图 5-24	0.001	0.000	0.000	0.001	0.000	0.000	0.000	<b>0.995</b>	0.003	0.000
图 5-25	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	<b>0.999</b>	0.000
图 5-26	0.006	0.003	0.011	0.002	0.000	0.001	0.001	0.018	<b>0.957</b>	0.002
图 5-27	0.000	0.000	0.001	0.000	0.000	0.000	0.000	0.000	<b>0.999</b>	0.000
图 5-28	0.000	0.000	0.001	0.000	0.000	0.000	0.000	0.000	0.000	<b>0.999</b>
图 5-29	0.000	0.000	0.000	0.000	0.000	0.010	0.000	0.000	0.000	<b>0.989</b>
图 5-30	0.000	0.000	0.000	0.000	0.000	0.001	0.000	0.000	0.000	<b>0.998</b>

### 3 模型测试与分析

#### 3.1 测试数据

利用训练好的模型对岩石薄片显微图像进行测试，以验证模型的识别效果。图 7 给出 30 张待测试图像，其中部分图像来源于网络，在图像结构、颜色、纹理、对比度等方面与训练集中的图像有明显差异。








图 7 30 张岩石薄片显微测试图像

(1-3)鲕粒;(4-6)堇青石;(7-9)石榴子石;(10-12)红柱石;(13-15)电气石;(16-18)十字石;(19-21)阳起石;(22-24)长石;(25-27)角闪石;(28-30)辉石

3.2 测试结果与分析

表 3 给出测试集岩石薄片显微图像的分类结果。测试图像整平均识别率为 96.7%，最低识别率为 78.0%，最高识别率为 100%。其中对图 7-1 所示的鲕粒，由于它内部的结构和其它岩石薄片图片差别比较大；对图 7-4 堇青石而言，由于打磨，丢失了图像显著的特征，所以识别率比较低；对图 7-25 角闪石，由于从网上找的图片比较模糊，在识别过程中，提取有效的特征不明显；对图 7-29 辉石而言，由于在采集岩石薄片图像的过程，岩石薄片视野不是很好，图像的特征信息丢失。与验证集相比，虽然测试集上识别率有所降低，但是不会产生明显的类别混淆。虽然图 7-8 石榴子石和图 7-21 的颜色差异比较大，图 7-22 长石整张图片中还有一部分不是岩石，图 7-28 辉石纹理特征不是很显著，但是它们的识别识别率比较好，说明了该模型具有较好的泛化能力。

表 3 测试集岩石薄片显微图像的分类结果

分类识别概率										
测试集 图像	鲕粒	堇青 石	石榴 子石	红柱 石	电气 石	十字 石	阳起 石	长石	角闪 石	辉石
图 7-1	<b>0.780</b>	0.002	0.000	0.004	0.004	0.188	0.000	0.012	0.010	0.001
图 7-2	<b>0.998</b>	0.000	0.001	0.000	0.000	0.001	0.000	0.000	0.000	0.000
图 7-3	<b>0.997</b>	0.002	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
图 7-4	0.001	<b>0.862</b>	0.000	0.078	0.038	0.003	0.009	0.001	0.000	0.012
图 7-5	0.001	<b>0.959</b>	0.001	0.005	0.000	0.006	0.007	0.014	0.005	0.000
图 7-6	0.000	<b>0.966</b>	0.000	0.003	0.012	0.015	0.001	0.001	0.000	0.002
图 7-7	0.000	0.000	<b>1</b>	0.000	0.000	0.000	0.000	0.000	0.000	0.000
图 7-8	0.002	0.000	<b>0.997</b>	0.000	0.000	0.000	0.000	0.000	0.001	0.000
图 7-9	0.010	0.001	<b>0.980</b>	0.000	0.000	0.004	0.000	0.000	0.000	0.005
图 7-10	0.000	0.000	0.000	<b>0.997</b>	0.0001	0.001	0.000	0.000	0.000	0.000
图 7-11	0.000	0.001	0.000	<b>0.996</b>	0.003	0.000	0.000	0.001	0.000	0.000
图 7-12	0.002	0.001	0.000	<b>0.996</b>	0.000	0.000	0.000	0.000	0.000	0.000
图 7-13	0.003	0.084	0.000	0.000	<b>0.907</b>	0.001	0.004	0.000	0.000	0.000
图 7-14	0.000	0.001	0.000	0.000	<b>0.999</b>	0.000	0.000	0.000	0.000	0.000
图 7-15	0.001	0.001	0.000	0.003	<b>0.982</b>	0.005	0.004	0.001	0.000	0.002
图 7-16	0.003	0.000	0.001	0.000	0.000	<b>0.995</b>	0.000	0.000	0.000	0.000
图 7-17	0.001	0.000	0.000	0.001	0.000	<b>0.959</b>	0.004	0.000	0.001	0.035
图 7-18	0.001	0.006	0.000	0.003	0.001	<b>0.988</b>	0.000	0.000	0.000	0.000
图 7-19	0.000	0.000	0.000	0.000	0.000	0.000	<b>0.999</b>	0.000	0.000	0.000
图 7-20	0.000	0.000	0.002	0.002	0.022	0.000	<b>0.973</b>	0.000	0.000	0.000
图 7-21	0.003	0.001	0.000	0.000	0.002	0.003	<b>0.986</b>	0.000	0.000	0.005
图 7-22	0.006	0.002	0.000	0.002	0.000	0.001	0.000	<b>0.955</b>	0.030	0.003
图 7-23	0.000	0.000	0.000	0.000	0.000	0.000	0.000	<b>1.000</b>	0.000	0.000
图 7-24	0.002	0.000	0.000	0.000	0.000	0.000	0.000	<b>0.988</b>	0.010	0.000
图 7-25	0.008	0.024	0.013	0.002	0.001	0.003	0.032	0.013	<b>0.867</b>	0.036
图 7-26	0.004	0.000	0.002	0.000	0.000	0.000	0.000	0.004	<b>0.988</b>	0.001
图 7-27	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	<b>0.999</b>	0.000
图 7-28	0.000	0.001	0.002	0.000	0.001	0.000	0.002	0.000	0.003	<b>0.991</b>



图 7-29	0.000	0.005	0.001	0.002	0.002	0.085	0.023	0.000	0.000	<b>0.883</b>
图 7-30	0.000	0.000	0.000	0.000	0.000	0.002	0.000	0.000	0.000	<b>0.998</b>

#### 4 结论

本文基于 Inception-V3 模型的深度学习迁移学习方法，实现了对鲕粒、堇青石、石榴子石、红柱石、电气石、十字石、阳起石、长石、角闪石、辉石 10 种岩石薄片显微图像进行识别分类，其识别概率可以达到 95% 以上，有些种类的岩石识别结果达 98%。这说明基于 Inception-V3 模型的深度学习迁移学习方法能够有效地实现岩石薄片显微图像识别与分类，该方法不需要人工手动的提取岩石薄片显微图像的特征，降低了主观因素的影响。此外，通过没有参与训练的测试集岩石薄片显微图像验证了该模型具有很好鲁棒性和泛化能力。

#### 参考文献:

- [1]付晶,吴胜和,付金华,胡龙全,张海峰,刘鑫.鄂尔多斯盆地陇东地区延长组储层定量成岩相研究[J].地学前缘,2013,20(02):86-97.
- [2]冉新权,吴胜和,付晶,魏新善,楚美娟.鄂尔多斯盆地陇东地区延长组低渗透储层孔隙结构分类研究[J].地学前缘,2013,20(02):77-85.
- [3]周翔,何生,刘萍,俱云娟.鄂尔多斯盆地代家坪地区长 6 致密油储层孔隙结构特征及分类评价[J].地学前缘,2016,23(03):253-265.
- [4]钟大康,祝海华,孙海涛,蔡超,姚泾利,刘显阳,邓秀芹,罗安湘.鄂尔多斯盆地陇东地区延长组砂岩成岩作用及孔隙演化[J].地学前缘,2013,20(02):61-68.
- [5]张少敏,操应长,朱如凯,蒯克来,王健,朱宁,户瑞宁.湖相细粒混合沉积岩岩石类型划分:以准噶尔盆地吉木萨尔凹陷二叠系芦草沟组为例[J].地学前缘,2018,25(04):198-209
- [6]潘荣,朱筱敏,谈明轩,张剑锋,李勇,邸宏利.库车坳陷克拉苏冲断带深部巴什基奇克组致密储层孔隙演化定量研究[J].地学前缘,2018,25(02):159-169.
- [7]张立强,严一鸣,罗晓容,王振彪,张海祖.库车坳陷依奇克里克地区下侏罗统阿合组致密砂岩储层的成岩差异性特征研究[J].地学前缘,2018,25(02):170-178.
- [8]久凯,丁文龙,王哲,黄勇,朱宝存,张振华,曾维特,王濡岳.黔北凤冈地区龙马溪组页岩储层储集空间划分与演化过程分析[J].地学前缘,2016,23(01):195-205.
- [9]张震,鲍志东.松辽盆地朝阳沟油田储层裂缝发育特征及控制因素[J].地学前缘,2009,16(04):166-172.
- [10]李海燕,岳大力,张秀娟.苏里格气田低渗透储层微观孔隙结构特征及其分类评价方法[J].地学前缘,2012,19(02):133-140.
- [11]王洛,李江海,师永民,赵越,马寅生.准噶尔盆地滴西地区石炭系火山岩储集空间及主控因素分析[J].地学前缘,2014,21(01):205-215.
- [12]Jiang F , Gu Q , Hao H , et al. A method for automatic grain segmentation of multi-angle cross-polarized microscopic images of sandstone[J]. Computers & Geosciences, 2018:S0098300417308178.
- [13]Izadi H , Sadri J , Mehran N A . A new intelligent method for Minerals segmentation in thin Sections based on A novel incremental color clustering[J]. Computers & Geosciences, 2015, 81(C):38-52.
- [14]Lu B , Cui M , Liu Q , et al. Automated grain boundary detection using the level set method[J]. Computers & Geosciences, 2009, 35(2):267-275.
- [15]Obara B , Kozusnikova A , Scucka J . Automatic identification of microcracks observed on microscopic images of coarse-grained sandstone[J]. International Journal of Rock Mechanics & Mining Sciences, 2011, 48(4):681-686.

- [16]Gorsevski P V , Onasch C M , Farver J R , et al. Detecting grain boundaries in deformed rocks using a cellular automata approach[J]. Computers & Geosciences, 2012, 42(none):136-142.
- [17]Boyuan Ma,Xiaojuan Ban,Ya Su,Chuni Liu,Hao Wang,Weihua Xue,Yonghong Zhi,Di Wu. Fast-FineCut: Grain boundary detection in microscopic images considering 3D information[J]. Micron,2018.
- [18]Mingireanov Filho I , Vallin Spina T , Xavier Falc?O A , et al. Segmentation of sandstone thin section images with separation of touching grains using optimum path forest operators[J]. Computers & Geosciences, 2013, 57:146-157.
- [19]Jungmann M , Pape H , Wi?Kirchen P , et al. Segmentation of thin section images for grain size analysis using region competition and edge-weighted region merging[J]. Computers & Geosciences, 2014, 72:33-48.
- [20]Krizhevsky A ,Sutskever I , Hinton G . ImageNet Classification with Deep Convolutional Neural Networks[C]// NIPS. Curran Associates Inc. 2012.
- [21]Szegedy C , Vanhoucke V , Ioffe S , et al. [IEEE 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Las Vegas, NV, USA (2016.6.27-2016.6.30)] 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Rethinking the Inception Architecture for Computer Vision[J]. 2016:2818-2826.
- [22]周爱明, 马鹏鹏, 席天宇, et al. 基于深度学习的蝴蝶科级标本图像自动识别[J]. 昆虫学报, 2017.
- [23]蔡煜东, 宫家文, 甘骏人,等. 矿物分类和识别的人工神经网络模型[J]. 矿物学报, 1994(1):56-60.
- [24]席道瑛, 张涛. 前馈神经网络在矿物识别方面的应用[J]. 矿物学报, 1994(4):335-342.
- [25]李苍柏,范建福,宋相龙.深度学习在地质学上的应用[J].地质学刊,2018,42(01):115-121.
- [26]程国建,郭文惠,范鹏召.基于卷积神经网络的岩石图像分类[J].西安石油大学学报(自然科学版),2017,32(04):116-122.
- [27]陈晓君,陈小根,宋刚,陈根龙.基于人工神经网络模型的岩石特性预测[J].探矿工程(岩土钻掘工程),2019,46(01):34-38.
- [28]白林,姚钰,李双涛,徐东晶,魏昕.基于深度学习特征提取的岩石图像矿物成分分析[J].中国矿业,2018,27(07):178-182.
- [29]张野, 李明超, 韩帅. 基于岩石图像深度学习的岩性自动识别与分类方法[J]. 岩石学报, 2017, 34(2).
- [30]梅冥相.鲕粒成因研究的新进展[J].沉积学报,2012,30(01):20-32.
- [31]夏熠,石凯.堇青石合成过程中的物相及结构演变[J].硅酸盐通报,2018,37(09):2802-2805.
- [32]蔡逸涛,张洁,康丛轩,杨献忠,曹正琦,董钟斗,马玉广,施建斌.安徽栏杆含金刚石基性岩中石榴子石矿物学特征[J].地质通报,2019,38(01):110-120.
- [33]唐威,刘坤,李柳生,廖桂华,王青峰,石干,叶国田.红柱石粗颗粒预烧温度对莫来石-刚玉材料抗热震性的影响[J].耐火材料,2019,53(01):11-15.
- [34]金润成,李国武,金哲秀,全英林,郑昌日.电气石原料化学成分、制备方法对电气石陶瓷性能的影响[J].世界地质,2018,37(03):982-990.
- [35]黄杰,张聪,申婷婷,杨经绥,陈梅.拉萨地块林芝杂岩体含十字石石榴角闪岩的岩石学和变质过程研究[J].中国地质,2015,42(05):1588-1600.
- [36]钟倩,吴穹,廖宗廷,周征宇.广西黑青色阳起石玉振动光谱特征研究[J].光谱学与光谱分析,2018,38(06):1786-1792.
- [37]苏迎春.山东省长石矿成矿规律研究及找矿方向[J].山东国土资源,2019,35(02):16-23.

[38]刘建华,曹淑云,周丁奎,李俊瑜,程雪梅.红河-哀牢山剪切带角闪岩中角闪石变形特征及地震波各向异性研究[J/OL].地球科学:1-23[2019-05-15].

[39]洪文涛,王天刚,邢光福,姚仲友,林培军.矿物结构特征对岩浆混合过程的指示:以新西兰 Ruapehu 全新世安山岩中的辉石为例[J].高校地质学报,2015,21(03):478-491.